

Report Finale

Hotel Reviews

Booking.com

Ornella Fabiano

Luglio 2026

1. Introduzione

Questo report presenta un'analisi end-to-end di un dataset reale di recensioni alberghiere pubblicato su Booking.com, con l'obiettivo di individuare pattern nel comportamento dei recensori, differenze di performance tra hotel e città e correlazioni utili a supportare decisioni di revenue management nel settore turistico.

Il dataset di partenza (Hotel_Reviews.csv, circa 238 MB) raccoglie circa 515.000 recensioni pubblicate tra il 2015 e il 2017, relative a hotel situati in 6 città europee: Amsterdam, Barcellona, Londra, Milano, Parigi e Vienna. Dopo la fase di pulizia descritta nella sezione Metodologia, il dataset utilizzato per le analisi conta 515.212 recensioni (515.738 originarie, meno 526 duplicati esatti).

Nota sulla qualità dei dati (1.493 vs 1.494 hotel): la documentazione originale del dataset riporta 1.493 hotel. Un'analisi più approfondita ha rivelato che questo numero coincide esattamente con il conteggio degli indirizzi unici, non degli hotel realmente distinti. Sono stati infatti individuati due casi che spiegano la discrepanza: il nome "Hotel Regina" è condiviso da 3 hotel indipendenti in città diverse (Barcellona, Vienna, Milano), mentre un indirizzo a Londra (Trafalgar Square) è condiviso da 2 hotel con nomi diversi. Usando una chiave composta (nome + indirizzo), il conteggio corretto e verificato è di 1.494 hotel realmente distinti (il valore usato in questo report e nell'intero progetto).

2. Metodologia

L'analisi è stata condotta in quattro fasi sequenziali: pulizia dei dati in Python/pandas, progettazione e popolamento di un database relazionale MySQL, analisi dei dati con query SQL e pandas e visualizzazione dei risultati con Matplotlib.

2.1 Pulizia e preparazione dei dati (Python / pandas)

Dopo un'esplorazione iniziale (dimensioni, tipi di dato, valori mancanti, distribuzione di Reviewer_Score e Average_Score), il dataset è stato pulito: la colonna Review_Date è stata convertita in formato data, con estrazione di anno e mese come colonne separate; sono state rimosse 526 righe duplicate esatte (da 515.738 a 515.212 recensioni). Sono stati inoltre gestiti i valori mancanti nelle coordinate geografiche (lat/Ing): il missing risultava concentrato esclusivamente su 17 hotel specifici, non distribuito casualmente, ma un pattern sistematico (missing not at random). Le coordinate reali di questi 17 hotel sono state recuperate e imputate manualmente, evitando il bias geografico che l'eliminazione delle righe avrebbe introdotto.

Un pattern differente è stato riscontrato nella colonna Reviewer_Nationality: 522 recensioni (0,10% del totale) non riportano la nazionalità del recensore. Nel file originale questi valori sono codificati come un singolo carattere spazio, non come valore nullo. A differenza delle coordinate geografiche, qui il missing risulta distribuito casualmente su tutte le città (tasso tra 0,085% e 0,121% a seconda della città, nessuna concentrazione su hotel specifici) e riguarda un dato auto-dichiarato dal recensore, non ricostruibile da altre colonne. I valori mancanti sono stati quindi etichettati esplicitamente come "Not specified" anziché eliminati o imputati, per mantenere tracciabile il missing nelle analisi di nazionalità senza introdurre un valore non corretto.

Sono infine state create le variabili derivate necessarie alle analisi successive:

Total_Review_Length: calcolata come somma dei conteggi di parole negative e positive già presenti nel dataset originale.

Score_Category: suddivide il punteggio (Reviewer_Score) in 4 fasce (Basso 0–5, Medio 5–7, Buono 7–9, Ottimo 9–10), con intervalli allineati esattamente alla logica poi utilizzata nelle query SQL.

City: La costruzione della colonna City ha richiesto una verifica preliminare in più passaggi. È stato innanzitutto controllato e confermato che gli indirizzi coprono esattamente 6 paesi (Austria, Francia, Italia, Paesi Bassi, Regno Unito, Spagna) e che per 5 di essi la parola immediatamente precedente al nome del paese corrisponde sempre a un'unica città. Per il Regno Unito questo schema non era applicabile, poiché il codice postale si inserisce tra il nome della città e "United Kingdom"; è stato quindi verificato empiricamente che la stringa "London" compare comunque nel 100% degli indirizzi terminanti in "United Kingdom" (262.298 su 262.298), confermando che tutti gli hotel britannici del dataset si trovano a Londra. Solo dopo questa duplice verifica è stata costruita una mappa diretta paese→città, applicata uniformemente a tutte le righe.

days_since_review: campo già presente nel dataset originale (numero di giorni tra la data della recensione e la data di estrazione), fornito come stringa (es. "23 days"); ripulito e convertito in valore intero per poterlo includere nella heatmap delle correlazioni.

2.2 Progettazione del database (MySQL)

È stato progettato uno schema relazionale con 4 tabelle: **hotels**, **reviewers**, **reviews**, **hotel_stats**.

La tabella **hotels** utilizza una chiave univoca composta (nome + indirizzo), perché nessuno dei due campi preso singolarmente identifica un hotel in modo univoco: il nome "Hotel Regina" è condiviso da 3 hotel indipendenti (Barcellona, Vienna, Milano), mentre un indirizzo a Trafalgar Square (Londra) è condiviso da due hotel con nomi diversi. Il popolamento (515.212 righe) è stato eseguito tramite script Python (`pandas.to_sql`), più efficiente e affidabile della generazione manuale di istruzioni INSERT per un volume di dati di queste dimensioni. Al termine del popolamento sono stati verificati i conteggi delle righe per ciascuna tabella (**hotels** 1.494, **reviewers** 227, **reviews** 515.212, **hotel_stats** 1.494), la corretta relazione tramite JOIN tra hotel e recensioni e la distribuzione degli score per nazionalità.

2.3 Analisi con SQL e pandas

Sono state sviluppate 11 query SQL per rispondere alle domande di business richieste: andamento temporale, profilo dei recensori, performance di hotel e città, correlazioni sulla lunghezza delle recensioni. Le analisi principali sono state poi riprodotte in pandas e confrontate con i risultati SQL: la coincidenza è risultata esatta al 100% su tutti i confronti effettuati, confermando l'integrità della pipeline dati.

In pandas sono state inoltre create tre variabili di feature engineering, corrispondenti a due nuove analisi:

Sentiment_Score: punteggio normalizzato tra -1 e +1, calcolato come differenza tra parole positive e negative sul totale delle parole. Le recensioni prive di testo in entrambi i campi sono gestite esplicitamente per evitare una divisione per zero.

Sentiment_Label: etichetta categorica a tre stati (Positivo, Negativo, Neutro), assegnata in base al segno di **Sentiment_Score**.

City_Score_Cluster: raggruppamento delle città in tre fasce di qualità percepita (Fascia Bassa, Fascia Media, Fascia Alta), ottenuto con `pandas.qcut` sul punteggio medio per città e successivamente unito al dataset principale.

2.4 Visualizzazioni

Sono stati prodotti 8 grafici Matplotlib, presentati e commentati nella sezione *Risultati*.

3. Risultati

3.1 Trend temporali recensioni

Il volume di recensioni copre il periodo da agosto 2015 ad agosto 2017, oscillando tra circa 18.000 e 27.000 recensioni al mese. Si osserva una stagionalità estiva marcata, con i picchi assoluti a luglio e agosto 2016 (rispettivamente 25.865 e 27.252 recensioni), coerente con l'aumento dei viaggi turistici in Europa nei mesi estivi. Il calo evidente ad agosto 2017 (4.076 recensioni) non riflette una reale flessione della domanda, ma il fatto che l'estrazione del dataset si interrompe a metà mese.




Grafico 1 — Andamento recensioni per mese, per anno e stagionalità mensile aggregata (2015–2017)

Un'analisi complementare sui picchi di recensioni per singolo hotel conferma questo pattern: tutti i 10 hotel con il maggior numero di recensioni concentrate in un singolo mese (il caso più estremo è lo Strand Palace Hotel, con 304

recensioni a febbraio 2016) si trovano a Londra ed è coerente con il volume complessivo della città (approfondito nella sezione 3.3).

3.2 Profilo nazionalità recensori

Nel dataset sono rappresentate 227 categorie di nazionalità: 226 realmente dichiarate più la categoria esplicita "Not specified", assegnata alle 522 recensioni (0,10% del totale) prive di questo dato. Il Regno Unito è, con ampio margine, la nazionalità più rappresentata: 245.110 recensioni, pari al 47,6% del totale (quasi la metà di tutte le recensioni del dataset). Seguono Stati Uniti (35.349, 6,9%) e Australia (21.648, 4,2%). Le restanti 9 nazionalità più rappresentate (USA, Australia, Irlanda, Emirati Arabi Uniti, Arabia Saudita, Paesi Bassi, Svizzera, Germania, Canada) sommate insieme (24,1%) non raggiungono comunque il peso della sola UK.




Grafico 2 — Top 10 nazionalità dei recensori per volume di recensioni

Confrontando i punteggi assegnati, i recensori del Regno Unito risultano leggermente più generosi della media: score medio di 8,49 contro 8,31 per il resto delle nazionalità. Il box plot conferma che le distribuzioni delle prime 3 nazionalità (Regno Unito, USA, Australia) sono simili tra loro, concentrate nella fascia alta (mediana intorno a 9,2), con alcuni outlier verso il basso.




Grafico 4 — Distribuzione del punteggio (Reviewer Score) per le prime 3 nazionalità

La tabella seguente riporta volume e score medio per tutte le prime 10 nazionalità (le altre 217 nazionalità presenti nel dataset sommate insieme rappresentano il restante 28,3% delle recensioni):

Nazionalità	Recensioni	% sul totale	Score medio
United Kingdom	245110	47.6%	8.49
United States of America	35349	6.9%	8.79
Australia	21648	4.2%	8.59
Ireland	14814	2.9%	8.46
United Arab Emirates	10229	2.0%	7.88
Saudi Arabia	8940	1.7%	7.88
Netherlands	8757	1.7%	8.13
Switzerland	8669	1.7%	8.16
Germany	7929	1.5%	8.13
Canada	7883	1.5%	8.55

3.3 Performance città e hotel

Londra genera il volume di recensioni di gran lunga maggiore (262.298, pari al 50,9% del totale), seguita a distanza da Barcellona (60.149) e Parigi (59.413).




Grafico 3 — Volume di recensioni totali per città

Nonostante il volume nettamente superiore, Londra registra però il punteggio medio più basso tra le 6 città (8,32); Barcellona e Vienna guidano invece la classifica per qualità percepita (8,55 e 8,55). Questo risultato smentisce l'aspettativa che una città con più recensioni sia anche quella meglio valutata: è plausibile che l'elevato volume di recensioni raccolte a Londra aumenti semplicemente la probabilità statistica di intercettare esperienze negative, oltre a riflettere eventualmente un'offerta alberghiera mediamente più eterogenea.




Grafico 7 — Punteggio medio delle recensioni per città

Nota: l'asse Y di questo grafico parte da 8,1 e non da 0, per rendere visibili le differenze tra valori vicini tra loro (8,32–8,55). Questo comporta che le differenze visive tra le barre appaiano più marcate di quanto non siano in valore assoluto: il range reale è di soli 0,23 punti su una scala 0–10.

A livello di singolo hotel, il Ritz Paris guida la classifica per punteggio medio dichiarato (9,8 su 122 recensioni), seguito da diversi hotel a Barcellona e Vienna con basi di recensioni più ampie (600+). Un confronto complementare tra il punteggio medio calcolato sui dati 2015–2017 e l'Average_Score dichiarato da Booking (calcolato sull'ultimo anno di recensioni) evidenzia come caso più estremo il Kube Hotel Ice Bar con un gap di -1,35 punti, segno di un probabile miglioramento della qualità percepita nel tempo rispetto alla media storica completa.

La tabella seguente riassume le metriche principali per città, compreso il raggruppamento in fasce di qualità percepita (City_Score_Cluster) ottenuto in pandas:

Città	Recensioni	% sul totale	Score medio	Fascia
London	262298	50.9%	8.32	Bassa
Barcelona	60149	11.7%	8.55	Alta
Paris	59413	11.5%	8.42	Media
Amsterdam	57211	11.1%	8.46	Media
Vienna	38937	7.6%	8.55	Alta
Milan	37204	7.2%	8.35	Bassa

Le tre fasce sono bilanciate per numero di città (2 ciascuna), ma non per volume di recensioni: la Fascia Bassa raccoglie da sola il 58,1% del totale (Londra e Milano insieme), contro il 19,2% della Fascia Alta (Barcellona e Vienna), come si ricava dal clustering City_Score_Cluster descritto in Metodologia (sezione 2.3). Lo squilibrio è determinato quasi interamente dal peso di Londra, non da una reale prevalenza di esperienze negative nel mercato.

3.4 Correlazioni score-lunghezza

La lunghezza della recensione (in numero di parole) è debolmente correlata in negativo con il punteggio assegnato ($r = -0,168$): le recensioni più lunghe tendono, in media, a punteggi leggermente più bassi.




Grafico 6 — Relazione tra lunghezza della recensione e punteggio assegnato, per nazionalità

Nota: il grafico mostra un campione casuale di 5.000 recensioni (anziché l'intero dataset di 515.212), per evitare sovrapposizione dei punti (overplotting) e rendere il grafico leggibile.

Questo emerge chiaramente anche guardando la distribuzione per categoria di score: le recensioni “Basso” (punteggio 0–5) contano in media 55,5 parole, contro le 31,7 parole delle recensioni “Ottimo” (9–10); chi è insoddisfatto tende a motivare di più il proprio giudizio, mentre chi è soddisfatto lascia commenti più brevi.




Grafico 5 — Distribuzione della lunghezza della recensione per categoria di punteggio




Grafico 8 — Matrice di correlazione tra le variabili numeriche

Nota: nella matrice di correlazione compaiono anche valori di 0,83 (lunghezza vs conteggio parole negative) e 0,65 (lunghezza vs conteggio parole positive). Queste correlazioni sono meccaniche e non costituiscono un insight di business: Total_Review_Length è costruita come somma dei conteggi di parole positive e negative, quindi la correlazione elevata è un artefatto della definizione della variabile, non una relazione di causa-effetto.

Un'analisi complementare basata sul sentiment testuale (rapporto tra parole positive e negative nella recensione, normalizzato tra -1 e +1) rivela un quadro più bilanciato di quanto suggerito dai soli punteggi numerici: il 53% delle recensioni ha sentiment positivo, il 44% negativo e il restante 3% neutro (parità tra parole positive e negative, o recensione priva di testo). Nonostante il forte bias positivo nei voti numerici (mediana Reviewer_Score di 8,8), quasi la metà delle recensioni contiene testualmente più critiche che elogi: un segnale che i clienti tendono ad assegnare voti relativamente generosi anche quando la loro esperienza, descritta a parole, non è stata pienamente positiva.

Sentiment	Recensioni	%
Positivo	271316	53%
Negativo	228053	44%
Neutro	15843	3%

4. Conclusioni:

- **Barcellona e Vienna, non Londra, guidano la qualità percepita**

I dati mostrano che Barcellona (8,55) e Vienna (8,55) hanno lo score medio più alto tra le 6 città, mentre Londra è ultima (8,32) nonostante generi da sola oltre metà del volume di recensioni. Un revenue manager dovrebbe considerare Londra come il mercato a più alto volume, ma a maggiore rischio reputazionale, mentre Barcellona e Vienna rappresentano benchmark di qualità percepita.

- **I recensori britannici sono relativamente più generosi**

Con un punteggio medio di 8,49 contro 8,31 del resto delle nazionalità, i recensori del Regno Unito tendono a valutare in modo leggermente più permissivo. Dato il loro peso schiacciante nel dataset (47,6% delle recensioni), questo comportamento ha un effetto rilevante sullo score medio complessivo percepito da ogni hotel.

- **Le recensioni negative sono più lunghe e più dettagliate**

I clienti insoddisfatti scrivono in media il 75% di parole in più rispetto a quelli pienamente soddisfatti (55,5 contro 31,7 parole). Per un team di gestione della reputazione, questo significa che le recensioni più lunghe meritano priorità di lettura: tendono a contenere più dettagli specifici e azionabili sui problemi da correggere.

- **Volume elevato di recensioni non equivale a qualità elevata**

Il caso di Londra dimostra che un volume di recensioni molto più alto delle altre città coincide con lo score medio più basso, non il più alto. Questo può riflettere sia un effetto puramente statistico (più osservazioni raccolte aumentano la probabilità di includere esperienze negative), sia un'offerta alberghiera mediamente più eterogenea nel mercato londinese.

- **Il sentiment testuale è più critico di quanto suggeriscano i voti numerici**

Nonostante la mediana di Reviewer_Score sia pari a 8,8, il 44% delle recensioni contiene testualmente più critiche che elogi, contro il 53% a prevalenza positiva e il 3% neutro. Per un revenue manager, questo significa che affidarsi solo al punteggio medio rischia di nascondere segnali di insoddisfazione che compaiono nel testo: monitorare il contenuto qualitativo delle recensioni, oltre al punteggio, permette di intercettare problemi ricorrenti prima che si riflettano in un calo dello score.

Nota: Si evidenzia che, contrariamente a quanto ipotizzato come scenario illustrativo nelle linee guida del progetto (che indicavano Londra leader per qualità percepita), l'analisi empirica sui dati reali ha mostrato un trend opposto. Londra si posiziona infatti all'ultimo posto tra le sei città europee analizzate per punteggio medio (8,32).